

Practice

- 编程实现两个数据挖掘算法
- 提交源代码及测试报告
- 测试数据集须选自UCI Machine Learning Repository
(<https://archive.ics.uci.edu/>)
- 独立完成

Final

- 内容：数据挖掘实战
- 形式：科技小论文
- 独立完成， 5月31日23:59 提交 18215526500@163.com
- 邮件标题： **【数据挖掘】** + 学号+姓名

项目目的

- 本期末综合工程实践项目旨在全面考查学生对《数据挖掘导引》课程核心知识与技能的掌握情况，包括数据获取与理解、数据预处理、探索性数据分析、特征工程、模型构建与评估、结果可视化以及学术论文写作等多方面能力。通过完成一个完整的数据挖掘项目，学生应能够**独立地**经历从原始数据到可交付研究成果的全流程，为今后的科研与工程实践打下坚实基础。
- 根据课程覆盖的知识模块（数据预处理、关联分析、分类与预测、聚类分析），本项目提供方向1与方向2两个候选题目——分别对应**回归/分类与关联分析+聚类**两大任务范式。
- 学生**二选一**完成即可。

方向1：房价预测

• 问题描述

房屋价格受地段、面积、装修、建造年份等多种因素影响。准确预测房价不仅是房产交易决策的重要参考，也是银行抵押贷款评估、房地产投资分析的关键依据。随着房地产市场的日益活跃，如何从大量历史交易数据中挖掘出影响房价的关键因素，并建立可靠的预测模型，已成为数据挖掘技术的重要应用场景。

本题要求对房屋信息数据进行分析，**构建回归模型预测房屋价格（SalePrice）**，分析影响房价的主要特征，并在此基础上完成数据挖掘全流程。

• 数据集

名称：House Prices — Advanced Regression Techniques（Kaggle竞赛数据集）

获取地址：<https://www.kaggle.com/c/house-prices-advanced-regression-techniques/data>

数据规模：

训练集：约1,460条记录，81个特征（含房屋面积、建造年份、地段、房间数、地下室条件、车库类型等）

测试集：约1,459条记录

方向2：电商用户分群

• 问题描述

在电子商务蓬勃发展的今天，了解用户群体的消费特征对于精准营销和个性化推荐至关重要。不同消费习惯的用户需要差异化的运营策略——高价值用户需要维护和关怀，价格敏感型用户适合促销活动，品类偏好明确的用户则可进行定向推荐。

本题要求利用**零售交易数据**，通过聚类算法对用户进行分群，识别不同消费偏好的用户群体，并利用关联规则挖掘发现商品之间的搭配购买模式，最终给出有业务价值的运营建议。该题同时考查关联分析与无监督学习（聚类）两大模块的核心技术。

• 数据集

名称：Online Retail II (UCI Machine Learning Repository)

获取地址：<https://archive.ics.uci.edu/dataset/502/online+retail+ii>

数据规模：

约52万条交易记录，覆盖2009年12月至2010年12月，包含：Invoice（订单号）、StockCode（商品编码）、Description（商品描述）、Quantity（数量）、InvoiceDate（订单日期）、Price（单价）、Customer ID（客户ID）、Country（国家）等字段